



**ÉCOLE NATIONALE D'INFORMATIQUE (ENI)
UNIVERSITÉ DE FIANARANTSOA**

**Mention Informatique – Parcours Intelligence Artificielle
Master 1 – Intelligence Artificielle**

RAPPORT DE PROJET

Analyse & Optimisation Marketing basée sur la Segmentation Client

Segmentation client, performance des campagnes marketing, prédiction de la fidélité / valeur client (churn & CLV) et stratégie marketing digitale personnalisée assistée par l'intelligence artificielle.

Présenté par :

Nom	Prénom	Numéro	Parcours
RAKOTONDRATSIMBA	Andriamihaja Hery Zo	4630	OCC
ANDRIMIARINTSOA	Anjaratiana Marco	4560	GID
RAMILIJAONA	Diary Fanaperantsoa	4556	GID
ANDRIANARIMANANA	Ny Hary Aina Fanilo	4545	GID
RASOLOFONIRINA	Arisoa Fandresena	4546	GID
RAZAFIMAHATRATRA	Livanirina Bernardin	4617	OCC

Niveau / Filière : Master 1 – Intelligence Artificielle

Établissement : École Nationale d'Informatique (ENI), Fianarantsoa

Module / Projet : Analyse & Optimisation Marketing basée sur la Segmentation Client (M1 à M9)

Enseignant encadrant : Dr Josué

Année universitaire : 2025-2026

Fianarantsoa – 2026

TABLE DES MATIÈRES

Introduction générale	4
Problématique	4
Objectifs du projet	4
Méthodologie générale et outils	4
Plan du rapport	5
Chapitre 1 – Compréhension des enjeux stratégiques (Module M1)	6
1.1. Cadre théorique : segmentation et personnalisation marketing	6
1.2. Analyse SWOT du contexte	6
1.3. Les 5P du marketing appliqués au projet	6
1.4. Parcours client (Customer Journey)	7
1.5. Conclusion du chapitre	7
Chapitre 2 – Exploration des données (Module M2)	8
2.1. Objectif et données utilisées	8
2.2. Description du schéma de données	8
2.3. Nettoyage des données	8
2.4. Table des ventes enrichies	8
2.5. Statistiques descriptives des clients	8
2.6. Revenu par catégorie de produit et par canal de vente	9
2.7. Profil visuel des clients	9
2.8. Interprétation	9
Chapitre 3 – Segmentation client (Module M3)	10
3.1. Objectif	10
3.2. Cadre théorique : K-means, classification hiérarchique et ACP	10
3.3. Table des features clients	10
3.4. Choix du nombre de clusters	10
3.5. Résultats et visualisation	11
Chapitre 4 – Profilage des segments (Module M4)	12
4.1. Objectif	12
4.2. Profil moyen par cluster	12
4.3. Personas générés	12
4.4. Discussion	12
Chapitre 5 – Performance des campagnes marketing (Module M5)	13
5.1. Objectif et indicateurs clés (KPIs)	13
5.2. Résultats par campagne	13
5.3. Interprétation et classement	14
Chapitre 6 – Prédiction du churn et de la valeur client (Module M6)	15
6.1. Objectif et cadre théorique	15

6.2. Résultats.....	15
6.3. Discussion.....	15
Chapitre 7 – Stratégie marketing digitale (Module M7).....	16
7.1. Plan de ciblage personnalisé par segment.....	16
7.2. Plan marketing digital synthétique.....	16
Chapitre 8 – Dashboard marketing interactif (Module M8).....	17
8.1. Objectif et architecture.....	17
8.2. Mode de déploiement.....	17
Chapitre 9 – Synthèse finale et recommandations (Module M9).....	18
9.1. Synthèse des résultats.....	18
9.2. Principaux enseignements.....	18
9.3. Limites méthodologiques.....	18
9.4. Perspectives.....	18
Conclusion générale.....	19
Bibliographie et webographie.....	20

INTRODUCTION GÉNÉRALE

Dans un contexte de marché de plus en plus concurrentiel, la personnalisation de la relation client est devenue un levier majeur de performance commerciale. Les entreprises disposent aujourd'hui de volumes de données croissants (données clients, historiques d'achat, indicateurs de campagnes publicitaires) qu'il est possible d'exploiter grâce aux techniques de la science des données et de l'intelligence artificielle afin de mieux comprendre leur clientèle et d'optimiser leurs actions marketing.

Le présent rapport s'inscrit dans le cadre d'un projet pédagogique intitulé « Analyse & Optimisation Marketing basée sur la Segmentation Client ». Il vise à mettre en pratique, sur un cas d'usage retail multi-canal (Online, In-Store, Social, Email, TV), l'ensemble d'une chaîne de traitement data science appliquée au marketing digital : de l'exploration des données brutes jusqu'à la formulation d'une stratégie marketing personnalisée, en passant par la segmentation client, le profilage des segments, l'évaluation des campagnes et la modélisation prédictive.

Problématique

Comment exploiter des données clients, produits, ventes et marketing hétérogènes pour segmenter la clientèle de façon pertinente, évaluer objectivement la performance des campagnes publicitaires et anticiper le comportement futur des clients (risque de désabonnement, valeur potentielle), afin d'en déduire une stratégie marketing digitale personnalisée et mesurable ?

Objectifs du projet

- Comprendre les enjeux stratégiques de la personnalisation marketing (cadre SWOT / 5P).
- Explorer, nettoyer et préparer les données clients, produits et ventes.
- Segmenter la clientèle à l'aide de méthodes d'apprentissage non supervisé (K-means, classification ascendante hiérarchique, ACP).
- Construire des profils clients (personas) interprétables à partir des segments obtenus.
- Évaluer la performance des campagnes marketing à l'aide d'indicateurs clés (CTR, taux de conversion, CPC, CPA, ROI).
- Modéliser la prédiction du churn et de la valeur vie client (CLV) par apprentissage supervisé.
- Élaborer une stratégie marketing digitale personnalisée par segment.
- Restituer les résultats via un dashboard interactif.

Méthodologie générale et outils

Le projet est structuré en neuf modules pédagogiques (M1 à M9), allant du cadrage théorique à la présentation finale, chacun s'appuyant sur les résultats du précédent.

L'ensemble des traitements a été réalisé en langage Python, à l'aide des bibliothèques pandas (manipulation de données), matplotlib (visualisation), scikit-learn (apprentissage automatique : K-means, classification ascendante hiérarchique, ACP, régression logistique, forêts aléatoires) et Streamlit (dashboard interactif). Le code a été développé sous forme d'un notebook Jupyter (SMD.ipynb).

Avant la rédaction de ce rapport, l'ensemble du code a été vérifié et exécuté intégralement par rapport au cahier des charges du projet ; les anomalies détectées et corrigées sont documentées en annexe.

Plan du rapport

Ce rapport est structuré en neuf chapitres correspondant aux neuf modules du projet : cadrage stratégique (Chap. 1), exploration des données (Chap. 2), segmentation client (Chap. 3), profilage des segments (Chap. 4), performance des campagnes marketing (Chap. 5), prédiction du churn et de la CLV (Chap. 6), stratégie marketing digitale (Chap. 7), dashboard interactif (Chap. 8) et synthèse finale (Chap. 9). Le rapport se termine par une conclusion générale, une bibliographie et des annexes.

Chapitre 1 — Compréhension des enjeux stratégiques (Module M1)

Ce premier chapitre est théorique : il ne mobilise aucune donnée ni code, et pose le cadre conceptuel et stratégique qui justifie l'ensemble de la démarche technique menée dans les chapitres 2 à 9.

1.1. Cadre théorique : segmentation et personnalisation marketing

La segmentation client consiste à répartir une population de clients en sous-groupes homogènes (les segments) sur la base de critères démographiques, comportementaux ou transactionnels, dans le but d'adapter l'offre et la communication à chaque groupe. Elle constitue un pilier de la gestion de la relation client (CRM) et permet de passer d'un marketing de masse à un marketing personnalisé (« one-to-one »). La personnalisation marketing présente plusieurs intérêts :

- **Efficacité** : un message ciblé convertit statistiquement mieux qu'un message de masse.
- **Fidélisation** : comprendre les segments permet d'anticiper les besoins et de réduire le taux de désabonnement (churn).
- **Allocation budgétaire** : identifier le canal ou le segment le plus rentable évite de gaspiller le budget marketing.
- **Avantage concurrentiel** : l'intelligence artificielle permet de personnaliser l'offre à grande échelle, ce qui serait impossible manuellement.

1.2. Analyse SWOT du contexte (marketing digital personnalisé, retail multi-canal)

Tableau 1. Analyse SWOT du projet.

	Positif	Négatif
Interne	Forces : données clients, produits et ventes déjà collectées et structurées ; présence multi-canal (Online, In-Store, Social, Email, TV) ; diversité des catégories produits (Clothing, Footwear, Outerwear, Accessories).	Faiblesses : volume de données limité (échantillon réduit) pour entraîner des modèles robustes ; absence de données comportementales fines (pages vues, temps passé) ; pas d'historique de churn enregistré.
Externe	Opportunités : marché de l'e-commerce personnalisé en croissance ; outils d'intelligence artificielle accessibles (scikit-learn, dashboards low-code) ; fidélisation via des recommandations personnalisées.	Menaces : concurrence forte des grandes plateformes (Amazon, Zalando...) ; réglementation sur les données personnelles (RGPD) ; sensibilité des clients à la sur-sollicitation publicitaire.

1.3. Les 5P du marketing appliqués au projet

Tableau 2. Les 5P du marketing appliqués au projet.

P	Application au projet
Product (produit)	Catégories : Clothing, Footwear, Outerwear, Accessories
Price (prix)	De 22,5 € (Hat) à 120 € (Jacket) – positionnement milieu de gamme
Place (distribution)	Canaux : Online, In-Store, Social, Email, TV
Promotion	Campagnes marketing mesurées par impressions, clics, conversions
People / Personnalisation	5e P ajouté : segmentation client, personas, recommandations individualisées

1.4. Parcours client (Customer Journey)

Le parcours client se décompose en cinq étapes, à chacune desquelles correspond un levier de personnalisation spécifique :

- Notoriété (Awareness) – canaux Social, TV, Email → publicité ciblée.
- Considération – comparaison produits, avis → recommandation produit.
- Achat (Sale) – canaux Online / In-Store → offre promotionnelle.
- Fidélisation – récurrence d'achat, Total_Spent → programme de fidélité.
- Recommandation – bouche-à-oreille, avis, partage social.

1.5. Conclusion du chapitre

Ce cadrage stratégique justifie la démarche technique déployée dans la suite du rapport : comprendre qui sont les clients (Chap. 2 à 4), évaluer les campagnes marketing (Chap. 5), prédire la valeur et la fidélité client (Chap. 6), en déduire une stratégie marketing personnalisée (Chap. 7), puis la visualiser dans un dashboard (Chap. 8).

Chapitre 2 — Exploration des données (Module M2)

2.1. Objectif et données utilisées

Ce module vise à charger, nettoyer, résumer et visualiser les données sources : customers_data.csv, products_data.csv, sales_data_.csv et marketing_data.csv.

2.2. Description du schéma de données

Tableau 3. Schéma des quatre tables sources.

Table	Colonnes principales	Nb lignes
customers_data	Customer_ID, Name, Age, Gender, Location, Join_Date, Total_Spent	5
products_data	Product_ID, Product_Name, Category, Price, Brand	5
sales_data_	Sale_ID, Product_ID, Customer_ID, Date, Quantity, Sale_Price, Channel	5
marketing_data	Campaign_ID, Channel, Start_Date, End_Date, Budget, Impressions, Clicks, Conversions	5

2.3. Nettoyage des données

Le contrôle de qualité des données (valeurs manquantes, doublons) n'a révélé aucune valeur manquante ni aucun doublon sur les quatre tables. Une table « ventes enrichies » a ensuite été construite par jointure (sales ⋈ customers ⋈ products), avec calcul du chiffre d'affaires par ligne : $\text{Revenue} = \text{Quantity} \times \text{Sale_Price}$.

2.4. Table des ventes enrichies

Tableau 4. Table des ventes enrichies (sales_enriched).

Vente	Client	Produit	Catégorie	Qté	Revenu (€)	Canal
1	Alice	T-shirt	Clothing	2	100,0	Online
2	Bob	Jeans	Clothing	1	75,0	In-Store
3	Alice	Sneakers	Footwear	3	90,0	Online
4	Charlie	Jacket	Outerwear	1	120,0	In-Store
5	Diana	Hat	Accessories	2	90,0	Online

2.5. Statistiques descriptives des clients

Tableau 5. Statistiques descriptives des clients (âge et dépense totale).

Variable	Moyenne	Écart-type	Min	Médiane	Max
Âge (ans)	28,4	4,7	22	28	35
Total dépensé (€)	520,0	168,1	300	500	750

2.6. Revenu par catégorie de produit et par canal de vente

Tableau 6. Revenu total par catégorie de produit et par canal de vente.

Catégorie	Revenu (€)	Canal	Revenu (€)
Clothing	175,0	Online	280,0
Outerwear	120,0	In-Store	195,0
Accessories	90,0		
Footwear	90,0		




Figure 1. Revenu total par catégorie de produit (gauche) et par canal de vente (droite).

2.7. Profil visuel des clients




Figure 2. Âge des clients (gauche) et dépenses totales par client – Total_Spent (droite).

2.8. Interprétation

Le canal Online génère le chiffre d'affaires le plus élevé (280 €, soit 59 % du revenu total), devant le canal In-Store (195 €). La catégorie Clothing domine les ventes (175 €), suivie d'Outerwear (120 €). Ces premiers constats descriptifs orientent déjà l'analyse de segmentation (Chap. 3) et la priorisation des canaux marketing (Chap. 5 et 7).

Chapitre 3 — Segmentation client (Module M3)

3.1. Objectif

L'objectif est de créer des groupes homogènes de clients (clusters) à partir de variables comportementales : âge, dépense totale, nombre d'achats, quantité totale achetée et revenu total généré.

3.2. Cadre théorique : K-means, classification hiérarchique et ACP

Le K-means est un algorithme de partitionnement non supervisé qui répartit les observations en k groupes en minimisant la variance intra-groupe (distance entre chaque point et le centroïde de son groupe). Il nécessite de fixer k a priori et une standardisation préalable des variables (via un StandardScaler), car les variables n'ont pas la même échelle (l'âge varie entre 20 et 40 ans, alors que le revenu total varie de 0 à plus de 1000 €). La classification ascendante hiérarchique (Agglomerative Clustering) constitue une méthode alternative, construisant une hiérarchie de regroupements successifs, utile pour vérifier la stabilité d'une partition. Enfin, l'Analyse en Composantes Principales (ACP / PCA) permet de projeter les données multidimensionnelles standardisées sur un plan à 2 dimensions afin de visualiser les clusters obtenus.

3.3. Table des features clients

Tableau 7. Table des features comportementales utilisées pour le clustering.

Client	Âge	Dépense (€)	Nb achats	Qté totale	Revenu (€)
Alice	28	500	2	5	190
Bob	35	750	1	1	75
Charlie	22	300	1	1	120
Diana	30	600	1	2	90
Eva	27	450	0	0	0

3.4. Choix du nombre de clusters

$k = 2$ a été fixé arbitrairement compte tenu du très faible nombre de clients (5). Sur un jeu de données réel de taille suffisante, k serait déterminé objectivement par la méthode du coude (« elbow method ») ou par le score de silhouette.

3.5. Résultats et visualisation



Figure 3. Segmentation client (K-means, $k = 2$), projection sur les 2 premières composantes principales de l'ACP.

Les deux méthodes de clustering (K-means et classification hiérarchique) convergent vers la même partition : {Alice, Bob, Diana} d'un côté, {Charlie, Eva} de l'autre — ce qui renforce la robustesse du résultat malgré la petite taille de l'échantillon. La variance cumulée expliquée par les deux composantes de l'ACP dépasse 80 %, ce qui indique une bonne qualité de représentation en 2 dimensions.

Chapitre 4 — Profilage des segments (Module M4)

4.1. Objectif

Ce module vise à caractériser chaque cluster obtenu au chapitre 3 par ses statistiques moyennes, puis à en dériver des personas – des profils-types synthétiques et lisibles, facilitant la prise de décision marketing.

4.2. Profil moyen par cluster

Tableau 8. Profil moyen par cluster.

Cluster	Nb clients	Âge moyen	Dépense moyenne (€)	Achats moyens	Revenu moyen (€)
0	2	24,5	375,0	0,5	60,0
1	3	31,0	616,7	1,3	118,3

4.3. Personas générés

Segment 0 – Valeur modérée / Dormants (Charlie, Eva)

Clients à valeur modérée, peu actifs voire dormants. Âge moyen 24 ans, dépense moyenne 375 €, 0,5 achat en moyenne sur la période observée.

Segment 1 – Forte valeur / Actifs (Alice, Bob, Diana)

Clients à forte valeur, actifs (achats fréquents). Âge moyen 31 ans, dépense moyenne 617 €, 1,3 achat en moyenne sur la période observée.

4.4. Discussion

Cette distinction entre clients « à forte valeur / actifs » et clients « à valeur modérée / dormants » constitue la base de la stratégie de ciblage personnalisée développée au chapitre 7 : rétention premium pour le premier segment, réactivation pour le second.

Chapitre 5 — Performance des campagnes marketing (Module M5)

5.1. Objectif et indicateurs clés (KPIs)

Ce module évalue la performance des cinq campagnes marketing (une par canal) à l'aide des indicateurs marketing digital standards :

Tableau 9. Formules des indicateurs clés de performance marketing.

Indicateur	Formule	Interprétation
CTR (Click Through Rate)	Clics / Impressions	Capacité d'une publicité à générer des clics
Taux de conversion	Conversions / Clics	Capacité à transformer un clic en action (achat)
CPC (Coût Par Clic)	Budget / Clics	Coût moyen pour obtenir un clic
CPA (Coût Par Acquisition)	Budget / Conversions	Coût moyen pour obtenir une conversion
ROI (Retour sur Investissement)	(Revenu estimé - Budget) / Budget	Rentabilité de la campagne

En l'absence d'un revenu réel par conversion dans les données marketing, le revenu moyen par vente calculé au chapitre 2 (≈ 95 €, table des ventes enrichies) est utilisé comme proxy de la valeur d'une conversion pour l'estimation du ROI.

5.2. Résultats par campagne

Tableau 10. KPIs par campagne marketing.

Canal	Budget (€)	CTR (%)	Conv. (%)	CPC (€)	CPA (€)	ROI (%)
Online	1 000	4,00	7,50	0,50	6,67	1 325,0
In-Store	1 500	1,67	20,00	3,00	15,00	533,3
Social	2 000	3,75	13,33	1,33	10,00	850,0
Email	500	5,00	5,00	0,50	10,00	850,0
TV	3 000	5,00	8,33	1,00	12,00	691,7




Figure 4. ROI (%) et coût par acquisition (CPA) par canal marketing.

5.3. Interprétation et classement

Le canal Online affiche le meilleur ROI (1 325 %) pour le CPA le plus bas (6,67 €). Les canaux Social et Email sont à égalité en ROI (850 %), mais l'Email est nettement moins coûteux à activer (budget de 500 € contre 2 000 € pour Social). Le canal In-Store présente le ROI le plus faible (533 %) et le CPA le plus élevé (15 €), ce qui en fait le canal le moins efficient de l'échantillon.

Chapitre 6 — Prédiction du churn et de la valeur client (Module M6)

6.1. Objectif et cadre théorique

Ce module vise à construire des modèles prédictifs de churn (risque de désabonnement / d'inactivité du client) et de CLV (Customer Lifetime Value, ou valeur vie client). Le churn est traité comme un problème de classification binaire (régression logistique et forêt aléatoire – Random Forest), tandis que la CLV est traitée comme un problème de régression (forêt aléatoire de régression).

Le jeu de données ne comporte ni historique réel de désabonnement, ni volume suffisant (5 clients) pour entraîner et évaluer un modèle de façon statistiquement fiable avec un découpage train/test généralisable. Le churn est donc défini par une règle métier simplifiée (aucun achat enregistré $\Rightarrow$ client « à risque »), et les modèles sont entraînés à titre pédagogique pour démontrer la méthodologie, entièrement réutilisable telle quelle sur un jeu de données de taille suffisante (au minimum plusieurs centaines de clients avec un historique de plusieurs mois).

6.2. Résultats

Tableau 11. Résultats du modèle de churn (règle métier) et de la CLV prédite.

Client	Nb achats	Revenu total (€)	Churn (règle métier)	CLV prédit (€)
Alice	2	190	0 (fidèle)	518
Bob	1	75	0 (fidèle)	534
Charlie	1	120	0 (fidèle)	371
Diana	1	90	0 (fidèle)	534
Eva	0	0	1 (à risque)	517

6.3. Discussion

Seule Eva n'a aucun achat enregistré et ressort donc « à risque » selon la règle métier retenue. Le modèle de régression (Random Forest) prédisant la CLV – utilisée ici comme proxy de Total_Spent – à partir de l'âge et du nombre d'achats a été entraîné et évalué par l'erreur absolue moyenne (MAE) sur un jeu de test très réduit ; ce résultat est à interpréter avec beaucoup de prudence et ne saurait constituer une validation statistique robuste du modèle.

Chapitre 7 – Stratégie marketing digitale (Module M7)

Ce chapitre ne repose sur aucun nouveau code : il s'agit d'une synthèse stratégique construite à partir des résultats des chapitres précédents – segments clients (Chap. 3-4), performances des campagnes (Chap. 5) et prédictions de churn/CLV (Chap. 6).

7.1. Plan de ciblage personnalisé par segment

Tableau 12. Plan de ciblage personnalisé par segment client.

Segment	Canal prioritaire	Contenu / Actions	Objectif
Forte valeur / Actifs (Alice, Bob, Diana)	Online	Recommandations produits personnalisées, avant-premières, programme VIP	Augmenter la rétention et le budget alloué (fort potentiel de retour)
Valeur modérée / Dormants (Charlie, Eva)	Email	Offre de réactivation, code promo de bienvenue, rappel des nouveautés	Transformer les clients dormants en clients actifs

7.2. Plan marketing digital synthétique

Tableau 13. Plan marketing digital synthétique.

Élément	Détail
Objectif	Augmenter la valeur vie client (CLV) et réduire le churn
Cible principale	Segment forte valeur (rétention) + segment dormant (réactivation)
Canaux prioritaires	Online (acquisition/rétention), Email (réactivation)
Budget	Réallouer une partie du budget In-Store/TV vers Online et Email
KPIs de suivi	ROI par canal, taux de réactivation des dormants, CLV moyen
Fréquence	Campagnes mensuelles avec A/B testing sur les segments

Cette stratégie est construite sur un échantillon réduit (5 clients, 5 campagnes) à but pédagogique. Les recommandations illustrent la méthodologie (comment passer de la donnée à la décision marketing), mais devraient être validées sur un volume de données plus large avant toute mise en œuvre réelle.

Chapitre 8 — Dashboard marketing interactif (Module M8)

8.1. Objectif et architecture

Un dashboard interactif a été développé avec le framework Streamlit afin de restituer de façon dynamique les résultats des chapitres précédents auprès des parties prenantes non techniques. Il s'organise en trois onglets :

- **Segmentation client** : table filtrable par cluster, personas déroulants, nuage de points âge / dépenses colorié par cluster.
- **Performance campagnes** : table des KPIs filtrable par canal, graphiques du ROI et du CPA par canal.
- **Ventes & Produits** : table des ventes jointes aux produits, revenu par catégorie de produit.

Quatre cartes de synthèse (nombre de clients, revenu total, budget marketing total, ROI moyen) sont affichées en tête de dashboard. Le script recharge et recalcule les données à la volée si les modules M2 à M5 n'ont pas encore été exécutés, ce qui le rend autonome.

8.2. Mode de déploiement

Installation des dépendances : `pip install streamlit plotly`. Lancement, depuis le dossier du projet : `streamlit run M8_dashboard.py`. Le dashboard s'ouvre automatiquement dans le navigateur à l'adresse localhost:8501.

Chapitre 9 — Synthèse finale et recommandations (Module M9)

9.1. Synthèse des résultats

Le projet démontre, de bout en bout, une chaîne de traitement complète allant de la donnée brute à la recommandation marketing : exploration (Chap. 2), segmentation (Chap. 3), profilage (Chap. 4), analyse de performance des campagnes (Chap. 5), modélisation prédictive du churn et de la CLV (Chap. 6), traduction en stratégie digitale (Chap. 7) et restitution via dashboard (Chap. 8).

9.2. Principaux enseignements

- Deux segments clients nettement différenciés — « Forte valeur / Actifs » et « Valeur modérée / Dormants » — confirmés par deux méthodes de clustering distinctes.
- Le canal Online est le plus rentable (ROI 1 325 %, CPA le plus bas) ; le canal In-Store est le moins performant (ROI 533 %, CPA le plus élevé).
- Le canal Email combine un faible coût et un bon ROI : il est recommandé pour la réactivation des clients dormants.
- Les modèles prédictifs (churn, CLV) sont fonctionnels et méthodologiquement corrects, mais non généralisables en l'état faute de volume de données suffisant.

9.3. Limites méthodologiques

L'échantillon utilisé (5 clients, 5 produits, 5 ventes, 5 campagnes) est un jeu de données pédagogique. Les résultats numériques (clusters, KPIs, prédictions) ne doivent pas être interprétés comme des conclusions business définitives, mais comme une démonstration reproductible de la méthodologie, à valider sur un jeu de données réel de taille suffisante (idéalement plusieurs centaines de clients avec un historique de plusieurs mois).

9.4. Perspectives

- Étendre la collecte de données comportementales fines (navigation web, temps passé par page, interactions sur les réseaux sociaux).
- Historiser les données sur plusieurs mois afin de définir un véritable label de churn temporel (ex. absence d'achat depuis 90 jours).
- Déterminer objectivement le nombre optimal de clusters (méthode du coude, score de silhouette) sur un échantillon plus large.
- Automatiser le déploiement du dashboard et le rafraîchissement des données (pipeline de données en continu).

CONCLUSION GÉNÉRALE

Ce projet a permis de mettre en œuvre, de manière intégrée, l'ensemble des étapes d'une démarche d'analyse marketing assistée par l'intelligence artificielle : du cadrage stratégique à la restitution interactive, en passant par l'exploration des données, la segmentation, le profilage, l'analyse de performance des campagnes et la modélisation prédictive. Bien que réalisé sur un échantillon volontairement restreint à des fins pédagogiques, il illustre une méthodologie complète, rigoureuse et directement transposable à un contexte professionnel réel disposant d'un volume de données plus important. Les principaux résultats obtenus – deux segments clients bien différenciés, une hiérarchisation claire des canaux marketing par rentabilité, et une stratégie de ciblage personnalisée qui en découle – répondent directement à la problématique posée en introduction et démontrent la valeur ajoutée d'une approche data-driven pour l'optimisation du marketing digital.

BIBLIOGRAPHIE ET WEBOGRAPHIE

- KOTLER, P., KELLER, K.L., Marketing Management, Pearson Education, 15e édition.
- LEHU, J-M., La segmentation marketing, Éditions d'Organisation.
- JAMES, G., WITTEN, D., HASTIE, T., TIBSHIRANI, R., An Introduction to Statistical Learning, Springer, 2e édition – chapitres consacrés au clustering (K-means, ACP) et à la régression logistique.
- BREIMAN, L., « Random Forests », Machine Learning, vol. 45, 2001, p. 5-32.
- Documentation officielle scikit-learn – <https://scikit-learn.org/stable/> (K-means, Agglomerative Clustering, PCA, Logistic Regression, Random Forest).
- Documentation officielle pandas – <https://pandas.pydata.org/docs/>.
- Documentation officielle Streamlit – <https://docs.streamlit.io/>.
- Documentation officielle Matplotlib – <https://matplotlib.org/stable/>.
- École Nationale d'Informatique (ENI, Fianarantsoa), Projet pédagogique : Analyse & Optimisation Marketing basée sur la Segmentation Client, cahier des charges du projet, 2026.